CoReTA 显卡部署能力与算力申请报告

供导师评估　2026 年 10 月 30 日

建议优先申请单张 RTX 4090 24GB 及可预约的稳定使用时段，用于 Qwen 4B 与 8B 模型的专家适配器微调、能力校准和多轮团队实验。4090D 或 3090 24GB 可作备选；现有双 2080 Ti 适合先做 4B 可行性验证。

项目研究具有实际任务优势的成员为何未被团队充分利用，以及怎样保留有益纠错。算力申请主要服务于可控专家构造和重复对照实验，不以部署最大模型为目标。

一 显卡与模型部署范围

下表为工程估算。标准 2080 Ti 按每卡 11GB，3090、4090 和原版 4090D 按每卡 24GB；实际版本、空闲显存和服务器状态待核。推理先按单活跃会话、8K 至 16K 总上下文测试。[1–4]

显卡	非量化推理	4bit 量化推理	专家微调	项目定位
双 1080 Ti 11GB × 2	3B 短输入可试 4B 须看缓存	4B 或 7 至 8B 可试 软件与速度需核	小模型适配器仅作探索 不建议主训练	备用推理与接口验证
双 2080 Ti 11GB × 2	3B 短输入起步 8B 需双卡分片	4B 与 8B 优先 14B 分片可试	先 4B QLoRA 8B 需测长度与显存	可启动小规模验证 不是单张 22GB 卡
RTX 3090 24GB	4B 与 8B 优先 14B FP16 装不下	8B 与 14B 优先 32B 属边界尝试	4B 与 8B QLoRA 14B 短序列待测	实用备选 单卡简化部署
RTX 4090 24GB	4B 与 8B 优先 14B FP16 装不下	8B 与 14B 优先 32B 属边界尝试	4B 与 8B QLoRA 14B 待实测	优先申请 兼顾训练与反复推理
RTX 4090D 24GB	与其他 24GB 卡 同容量范围	与其他 24GB 卡 同容量范围	4B 与 8B QLoRA 具体速度实测	可接受备选 显存并不高于 4090

实用范围不是绝对上限。32B 的 4bit 模型可能在短输入、低并发下装入 24GB，但不作为长讨论或微调的默认配置。以上训练建议均指 LoRA 或 QLoRA，不指全参数训练。

二 显存占用与部署边界

完整模型加载用于推理，与全参数微调是两件事。3B 模型的 FP16 纯权重约 6GB，11GB 显卡可作为短输入起点；训练还需梯度、优化器和反向传播中间结果，不能据权重大小判断能否训练。[8]

显存组成	用途	主要增长因素
模型权重	存放模型参数；量化可减少存储	参数量、精度及非量化模块
KV 缓存	复用已读文本的计算结果	上下文长度、生成长度、并发数
计算与框架	中间张量、注意力、CUDA 工作区	长输入、批量及注意力实现
微调附加项	梯度、优化器状态、训练激活及 LoRA	可训练参数、样本长度和训练方式

纯权重估算

模型规模	FP16 或 BF16 权重	理想 4bit 权重
3B 泛指	6.0 GB	1.5 GB
Qwen3 4B	8.0 GB	2.0 GB
Qwen3 8B	16.4 GB	4.1 GB
Qwen3 14B	29.6 GB	7.4 GB
Qwen3 32B	65.6 GB	16.4 GB

按官方约 4.0、8.2、14.8、32.8B 参数推算。GB 采用十进制。4bit 列未计量化元数据和非量化层；两列均未计缓存与工作区，不是运行显存。[5–7]

以 Qwen3 4B 与 8B 为例，按一个活跃会话、FP16 KV 缓存估算，8K、16K、32K 长度的缓存约为 1.125、2.25、4.5 GiB。多轮讨论历史和生成内容会持续增长；实际还需计入预填充峰值。

双 11GB 显卡不会自动合并成单张 22GB。分片部署需单独配置并承担通信开销；普通数据并行复制模型，不能解决每卡装不下。2080 Ti 的 Turing 架构也需单独核验 FP16、量化及注意力内核，不能照搬 4090 的 BF16 配置。[8–9]

三 项目需要的模型与服务器条件

优先候选是同一 Qwen 底座加一个任务 LoRA：普通成员使用底座，专家成员使用底座与适配器，再通过独立题目确认能力优势。四名逻辑 agent 可顺序调用同一份底座，各自保留独立上下文，不需同时常驻四份完整模型。

项目环节	起步方案	申请 4090 后的目标
基础推理	4B 量化完整题目测试	4B 与 8B 对比，视显存选择 FP16 或量化
专家构造	先验证 4B QLoRA 小步训练	优先测试 8B QLoRA，保留 4B 比较
团队交流	独答与逐发言历史完整保存	测试多轮讨论和完整终答，不为显存删证据
上下文预算	先测 8K 至 16K 总上下文	16K 实测通过后再探索 32K；不保证必能容纳
训练序列	按完整样本长度分布确定	2K 或 4K 可用于预检，正式训练不默认截断
结果验证	独立校准与普通团队基线	增加必要重复、对照和失败分析

配套服务器建议

项目	建议配置	说明
GPU	优先单张 RTX 4090 24GB	4090D 或 3090 24GB 可备选
主机内存	64GB 起步，128GB 更宽裕	供模型加载、数据处理及必要卸载；建议值
存储	建议预留 200GB SSD 工作空间	按模型缓存、检查点与日志实际占用调整
系统环境	Linux 及匹配的驱动和 PyTorch 环境	固定模型与依赖版本，旧卡兼容另测
使用方式	SSH 或作业队列及稳定预约时段	先核实际权限与空闲显存，再安排运行

4B 与 8B 已有协作研究先例。ICR 采用 Qwen3 4B 及 8B；When Debate Helps 采用 4B 与 7B 的四成员多轮轨迹。因此，小参数模型可以承担正式实证研究，但本项目是否产生足够的专家优势与正负交互事件，仍由校准和开发实验决定。[10–11]

四 优先申请 RTX 4090 的依据

研究用途与预期收益

第一，支持更合适的 8B 候选。相对每卡 11GB 的双 2080 Ti，单卡 24GB 更便于容纳底座、专家适配器、训练激活和较长输入，减少为适配显存而进行复杂跨卡切分的需要。8B 能否完成具体长度的训练，仍需小步实测。

第二，服务于多轮与重复实验。每题涉及成员独答、多个讨论发言、最终作答及无消息等对照；还需专家训练与独立校准。较强算力和稳定预约时段有利于缩短迭代周期，完成必要重复和错误分析。

第三，减少旧架构适配负担。4090 属于 Ada 架构，支持当前主线 FlashAttention 2 所列平台及 BF16 计算；相比 2080 Ti，可减少旧架构内核适配。具体软件组合及速度收益仍以本机验证为准。[3,9]

相对 3090，4090 的申请重点是计算性能与实验周转，而不是显存容量。两者标准显存均为 24GB，不能据 4090 型号宣称能部署明显更大的模型，也不承诺未经测试的速度倍数。若 3090 可提供更稳定的使用时段，仍是有效方案。

建议的申请方式

申请单张 RTX 4090 24GB 的服务器使用资源，先提供一周可预约验证窗口，用于环境配置、真实任务推理、峰值显存与吞吐测量、小规模专家适配器训练及能力校准。该窗口为排期建议，不代表持续满负载或承诺一周完成全部研究。

首阶段输出真实显存、吞吐、训练步耗时和校准结果，再据此核算后续 GPU 小时及预约周期。若 4090 暂不可得，依次评估可稳定使用的 4090D 或 3090；已有双 2080 Ti 用于并行推进 4B 验证。

可直接用于申请说明的文字

本项目拟研究多智能体团队对任务专家能力的利用与损失，需要在同一 Qwen 底座上构造任务专家适配器，并开展独立能力校准、多轮交流和重复对照实验。现有双 2080 Ti 可用于 4B 模型起步，但每卡 11GB 对 8B 微调及长输入的余量较小。拟优先申请单张 RTX 4090 24GB 及配套服务器使用时段，以降低部署复杂度、支持 8B 候选和必要的实验迭代。先进行一周可预约验证，提交实测用量后再申请后续配额；4090D 或 3090 24GB 可作为备选。

五 验收安排与依据来源

首阶段完成什么

步骤	交付与判断
1 核实资源	记录实际显卡和显存、系统、驱动、主存、存储与使用权限。
2 技术验证	以完整真实题目测推理、上下文增长、解析与显存峰值；记录截断和失败。
3 小规模微调	确认 LoRA 训练、保存、重新加载可用；按实测步耗时估总量。
4 科学校准	使用独立题目检查专家优势，再做普通团队、独思和初答投票比较。

GPU 部署成功不等于专家训练成功；专家形成优势也不等于团队必然受损。每个小阶段核对目标、证据与资源，再决定继续、修改或停止对应设置。当前仅完成资源与文献分析，未实测本报告中的机器，未启动模型部署或训练。

参考资料

[1] NVIDIA RTX 2080 Ti 官方规格

[2] NVIDIA RTX 3090 官方规格

[3] NVIDIA RTX 4090 官方规格

[4] NVIDIA RTX 4090D 官方规格

[5] Qwen3 4B 官方模型卡与配置

[6] Qwen3 8B 官方模型卡与配置

[7a] Qwen3 14B 官方模型卡

[7b] Qwen3 32B 官方模型卡

[8] Hugging Face 量化与 QLoRA 文档

[9] FlashAttention 官方硬件要求

[10] Li 等 Beyond Final Accuracy 预印本 2026

[11] Zhao 等 When Debate Helps 预印本 2026

规格与文献核验日期为 2026 年 10 月 30 日。显存范围为基于参数、缓存及常见部署方式的估算；没有声称完成实机基准。3B 为泛指参数规模，Qwen3 实例使用 4B、8B 等官方型号。